

Двухканальное разделение речи на временных сигналах с помощью Dual-Path RNN

М. Афанасьев, Д. Барсуков, А. Ковыляев
Faculty Of Computer Science, HSE, Moscow

Аннотация—Направление разделения источников звука из единого канала на отдельные аудио-дорожки на сегодняшний день активно развивается во множестве областей. В данной работе рассматривается задача разделения голосов двух дикторов, на основе записанного аудио микса. Целью исследования было продвинуться в качестве решения данной задачи за счет изучения и применения архитектуры, учитывающей временной параметр в своих предсказаниях. Для этой цели мы взяли рекуррентную нейронную сеть с двойным путём (Dual-Path Recurrent Neural Networks, DPRNN) [1] в которую передаются закодированные аудио-последовательности, обработанные сетью разделения аудиосигналов во временной области (Time-domain Audio Separation Network, TasNet) [2] и протестировали её на новом наборе данных из нашей задачи. Качество модели оценивалось с точки зрения зашумленности получившихся аудио-последовательностей, наряду с размерами и скоростью обработки входных данных.

I. Вступление

Разделение источников звука на моно сигналы - это задача, которая появляется в различных практических приложениях, таких как видеоконференции, шумоподавление и других. В её основе нам задается моносигнал, содержащий в себе записи нескольких источников звука. На выходе мы ожидаем увидеть несколько каналов, каждый из которых содержит в себе отдельную запись каждого самостоятельного источника, которая не зашумлена другими сигналами. За последние годы инструменты, для решения данной проблемы значительно продвинулись благодаря развитию глубинного обучения. Долгое время доминировали методы, работающие в частотной области и использующие спектрограммы (например, на основе кратковременного преобразования Фурье (Short-Time Fourier Transform, STFT) [9] и маскирование амплитудных спектров. Однако появление полностью временных архитектур показало, что прямое считывание сигнала во времени позволяет избежать потерь информации и ограничений, связанных с обратимыми преобразованиями. Одним из наиболее успешных временных подходов стал DPRNN, где длинная последовательность разбивается на блоки, а временные зависимости моделируются отдельно в пределах каждого блока и между блоками. В своей работе мы использовали описанную выше архитектуру, для решения проблемы разделения двух источников речи, слитых в общий звуковой ряд. Для сравнения и валидации подходов использовалась метрика Масштабно-инвариантное отношение

сигнал/шум (Scale-Invariant Signal-to-Noise Ratio, SI-SNR), отражающая чистоту полученного сигнала. В отличие от классического SNR эта метрика не зависит от масштаба амплитуды.

II. Постановка задачи и данные

Целью работы является исследование и реализация нейросетевой модели одноканального разделения речи, способной по входному аудиосигналу $x(t)$, содержащему сумму двух голосов,

$$x(t) = s_1(t) + s_2(t),$$

восстановить оценки исходных сигналов $\hat{s}_1(t)$ и $\hat{s}_2(t)$, максимально близкие к истинным $s_1(t)$ и $s_2(t)$ в смысле метрики SI-SNR и её приращения SI-SNRi.

Для обучения и валидации используется кастомный датасет, содержащий:

- смешанные сигналы (папка mix);
- отдельные каналы для первого и второго говорящего (папки s1 и s2);
- сопутствующую структуру разбиения на обучающую и валидационную части.

III. Методология

A. Общий обзор архитектуры DPRNN

DPRNN работает во временной области и строится вокруг идеи разбиения латентного представления аудиосигнала на перекрывающиеся сегменты фиксированной длины. После прохождения через энкодер исходная смесь $x(t)$ преобразуется в последовательность признаков

$$\mathbf{Y} = [\mathbf{y}_1, \dots, \mathbf{y}_T] \in \mathbb{R}^{T \times C},$$

где C — размерность скрытого пространства. Далее последовательность разбивается на чанки длиной K с перекрытием, в результате чего образуется тензор размера (B, N, K, C) , где N — число сегментов.

Каждый блок DPRNN состоит из двух последовательно применяемых рекуррентных подсетей:

- внутрисегментной (intra-chunk) RNN, которая моделирует зависимости внутри каждого сегмента длиной K ;
- межсегментной (inter-chunk) RNN, которая моделирует зависимости между сегментами по измерению N .

Обе RNN, как правило, реализуются двунаправленными LSTM с остаточными соединениями и нормализацией по каналам, что обеспечивает стабильность обучения и хорошую сходимость.

На выходе цепочки DPRNN-блоков полученное скрытое представление подаётся в маскирующий модуль, который для каждого из двух источников генерирует маску над латентными признаками. Применяя эти маски к энкодерному представлению, мы получаем две отдельные последовательности, которые затем декодируются обратно во временную область.

В. Реализация модели и кода

Наша реализация DPRNN в виде модульной архитектуры:

- Код модели. DPRNN разделена на независимые классы: энкодер, DPRNN-блоки, маскирующий модуль и декодер. Это упрощает модификации отдельных компонентов (например, изменение числа блоков или размера латентного пространства) без переписывания всей модели.
- Конфигурирование через Hydra. Все ключевые гиперпараметры (длина чанка, число DPRNN-блоков, размер скрытого слоя, выбор функции потерь, параметры оптимизатора) задаются в YAML-конфигурациях и передаются в код через Hydra. Это позволяет воспроизводить эксперименты и систематически исследовать влияние различных настроек.
- Тренировочный цикл. Обучение организовано через базовый класс `BaseTrainer`, который реализует общую логику эпох, логирования, сохранения чекпоинтов и ранней остановки. Специализированный `Trainer` реализует конкретные шаги для задачи разделения речи: вызов модели, вычисление функции потерь SI-SNR (с PIT или без) и расчёт метрик на батче.

С. Функция потерь и метрики

В качестве основной функции потерь используется SI-SNR, реализованная через модуль `PermutationInvariantTraining` из `torchmetrics`, который автоматически выбирает оптимальное сопоставление предсказанных и истинных источников и максимизирует SI-SNR по всем возможным перестановкам.

Качество работы модели оценивается по SI-SNRi и SDRi, вычисляемым как разность между значениями SI-SNR/SDR для выходных сигналов и для исходной смеси. Для анализа воспринимаемого качества и разборчивости речи могут также использоваться PESQ и STOI [4], [5], но в данном отчёте основной акцент сделан на SI-SNRi и SDRi.

IV. Эксперименты

А. Общая схема экспериментов

Все модели обучались на одном и том же датасете аудиоразделения (двухголосые смеси речи). Для обеспечения сопоставимости результатов мы использовали единый пайплайн: одинаковый лосс (SI-SNR с permutation invariant training), одинаковое разбиение на обучающую и валидационную части, а также общий набор метрик качества (SI-SNRi, SDRi, PESQ, STOI).

Основной целью серии экспериментов было последовательно улучшить качество DPRNN-модели за счёт изменения архитектуры и гиперпараметров а также сравнить DPRNN с сверточной архитектурой `ConvTasNet` и `RTFS-Net` [8], [3] в идентичных условиях обучения.

В. Эксперименты с DPRNN

1) Базовая DPRNN: В качестве отправной точки мы взяли DPRNN-модель с архитектурой, близкой к описанной в оригинальной статье.

Для базовой конфигурации использовались умеренные размеры:

- размер эмбединга энкодера: 512
- бутылочное сужение DPRNN: 128
- число DPRNN-блоков: 4
- стандартный шаг обучения из базового конфига (без дополнительного тюнинга)

После обучения на ограниченном числе эпох модель достигла примерно $\text{SI-SNRi} \approx 2$ на валидации. Кривая лосса убывала, но довольно быстро выходила на плато, а качество оставалось существенно ниже ожидаемого уровня.




Рис. 1. Динамика метрик для базовой DPRNN.

2) Изменение градиентного клиппинга: Далее мы попробовали стабилизировать за счёт менее агрессивного градиентного клиппинга:

- было выставлено ограничение $\text{max_grad_norm} = 5$.

На практике это привело к обратному эффекту:

- лосс уменьшался медленнее
- итоговое SI-SNRi оказалось даже ниже, чем у базовой модели без клиппинга

Таким образом, для нашей реализации DPRNN ограничение нормы градиента ухудшило оптимизацию, и мы отказались от этого варианта в дальнейшем.




Рис. 2. Динамика метрик для DPRNN с grad norm 5.

3) Увеличение мощности модели: Следующим этапом мы увеличили размеры DPRNN: мы увеличили число блоков и/или размер скрытых слоёв. Все остальные гиперпараметры оставались близкими к базовым. Результат:

- качество действительно немного выросло по сравнению с первой конфигурацией DPRNN
- SI-SNRi стал заметно выше 2, но всё ещё низким в контексте целевых значений для задачи разделения речи
- на валидации наблюдалась тенденция к переобучению: улучшения на трейне не полностью переносились на валидацию

Этот эксперимент показал, что увеличение числа параметров само по себе не решает проблему; ключевым становится подбор режима оптимизации.




Рис. 3. Динамика метрик для DPRNN увеличенной.

4) Тюнинг learning rate и финальная DPRNN: Понимая, что большая модель обладает достаточной предсказывающей способностью, мы сфокусировались на настройке шага обучения. На той же увеличенной DPRNN были проведены эксперименты с уменьшением learning rate (с сохранением остального пайплайна: SI-SNR+UPIT, те же данные, без агрессивного клиппинга).

Обнаружив удачную комбинацию размера модели и learning rate, мы запустили финальное обучение на 200

эпох. В этой конфигурации модель достигла SI-SNRi > 6 на валидационном наборе. Эту версию DPRNN мы рассматриваем как наш основной референс среди рекуррентных архитектур.




Рис. 4. Динамика метрик для DPRNN увеличенной + lr.

С. Эксперименты с ConvTasNet

В качестве сверточного базлайна мы реализовали и интегрировали модифицированную ConvTasNet-подобную модель. Архитектура строится по тому же принципу «энкодер–сепаратор–декодер», что и DPRNN, но вместо рекуррентных блоков использует стек TCN-блоков с дилатированными depthwise-свёртками и skip-коннектами.

Важные моменты:

- мы использовали те же TasNet-энкодер и декодер, что и в DPRNN, чтобы различия шли именно за счёт сепаратора;
- лосс и метрики полностью совпадают с DPRNN-экспериментами (SI-SNR с UPIT, SI-SNRi/SDRi/PESQ/STOI на валидации);
- режим обучения и датасет идентичны финальной конфигурации DPRNN.

На текущем этапе ConvTasNet показывает качество как минимум не хуже, а по ряду прогонов — даже лучше, чем наша финальная версия DPRNN (SI-SNRi > 6), при том что архитектура остаётся сравнительно простой и удобной для дальнейшей оптимизации. Добучая и подбирая параметры модели мы в дальнейшем сможем достигнуть на данной архитектуре даже более высоких результатов.




Рис. 5. Динамика метрик для ConvTasNet.

D. Попытка воспроизведения RTFS-Net

Первым шагом мы интегрировали в репозиторий модифицированный вариант RTFS-Net, сочетающий частотно-временную LSTM-обработку и визуальные признаки (FiLM-fusion для двух лиц). Модель была подключена к существующему трейнеру, лоссу SI-SNR и метрикам.

Несмотря на попытки стабилизировать обучение (ограничение длины аудио, подбор learning rate, упрощение архитектуры), RTFS-Net в нашей конфигурации так и не сошёлся до приемлемого качества. В дальнейшем мы рассматривали его как отрицательный результат и сосредоточились на DPRNN и ConvTasNet.

V. Выводы и дальнейшая работа

В данном отчёте мы рассмотрели постановку задачи одноканального разделения речи и описали архитектуру DPRNN, ориентированную на работу во временной области с учётом как локальных, так и глобальных зависимостей в аудиосигнале. В результате удалось достигнуть хорошего качества на нашей задаче. Полный список результатов можно найти в Приложении, таблица 1. В дальнейшем мы также планируем более детально протестировать архитектуру RTFS-Net, которая будет использовать дополнительную информацию - видеозаписи движения губ каждого спикера. Дополнительный слой параметров может значительно улучшить качество предсказаний модели за счет более глубокого понимания источников сигнала.

VI. Contribution

- М. Афанасьев: RTFS-Net, ConvTasNet, Dataset, Report
- Д. Барсуков: Обучение моделей, подбор гиперпараметров, тестирование моделей
- А. Ковыляев: DPRNN, Dataset, Demo, Inference

Список литературы

- [1] Y. Luo, C. Han, N. Mesgarani, "Dual-Path RNN: Efficient Long Sequence Modeling for Time-Domain Single-Channel Speech Separation," in Proc. ICASSP, 2020.
- [2] Y. Luo, N. Mesgarani, "TasNet: Time-Domain Audio Separation Network for Real-Time, Single-Channel Speech Separation," in Proc. ICASSP, 2018.
- [3] D. Pegg, X. Li, B. Hu, "RTFS-Net: Recurrent Time-Frequency Modelling for Efficient Audio-Visual Speech Separation," in Proc. ICLR, 2024.
- [4] ITU-T Recommendation P.862, "Perceptual Evaluation of Speech Quality (PESQ): An Objective Method for End-to-End Speech Quality Assessment of Narrow-band Telephone Networks and Speech Codecs," International Telecommunication Union, 2001.
- [5] C. H. Taal, R. C. Hendriks, R. Heusdens, J. Jensen, "A Short-Time Objective Intelligibility Measure for Time-Frequency Weighted Noisy Speech," in Proc. ICASSP, 2011.
- [6] D. P. Kingma, J. Ba, "Adam: A Method for Stochastic Optimization," arXiv preprint arXiv:1412.6980, 2014.
- [7] A. Ephrat et al., "Looking to Listen at the Cocktail Party: A Speaker-Independent Audio-Visual Model for Speech Separation," ACM Transactions on Graphics (SIGGRAPH), vol. 37, no. 4, 2018.

- [8] Y. Luo, N. Mesgarani, "Conv-TasNet: Surpassing Ideal Time-Frequency Magnitude Masking for Speech Separation," IEEE/ACM Transactions on Audio, Speech, and Language Processing, vol. 27, no. 8, pp. 1256–1266, 2019.
- [9] J. B. Allen, "Short Term Spectral Analysis, Synthesis, and Modification by Discrete Fourier Transform," IEEE Transactions on Acoustics, Speech, and Signal Processing, vol. 25, no. 3, pp. 235–238, 1977.

Приложение

Таблица I

Сравнение протестированных моделей по качеству разделения речи. Значения приведены на валидационном наборе;

Модель	SI-SNRi $\uparrow$	SDRi $\uparrow$	PESQ $\uparrow$	STOI $\uparrow$
DPRNN (базовая)	≈ 2.0	≈ 2.3	1.22	0.68
DPRNN + grad clip (max_grad_norm = 5)	< 1.0	< 1.0	1.19	0.65
DPRNN (увеличенная модель)	≈ 1.2	≈ 1.21	1.29	0.66
DPRNN (увеличенная, уменьшенный LR, 200 эпох)	6.0+	5.5+	1.42	0.80
ConvTasNet (наш вариант)	≈ 2.9	-	1.24	0.72
RTFS-Net (аудио-визуальная)	-	-	-	-